

REDES NEURONALES ARTIFICIALES – DEEP LEARNING

MODELOS DE ARQUITECTURA AVANZADA: RNN – GAN – REINFORCEMENT –
TRANSFER – AUTOENCODERS - TRANSFORMER Y MECANISMOS DE ATENCIÓN

LAURA DIAZ DÁVILA

RECURRENT NEURAL NETWORK

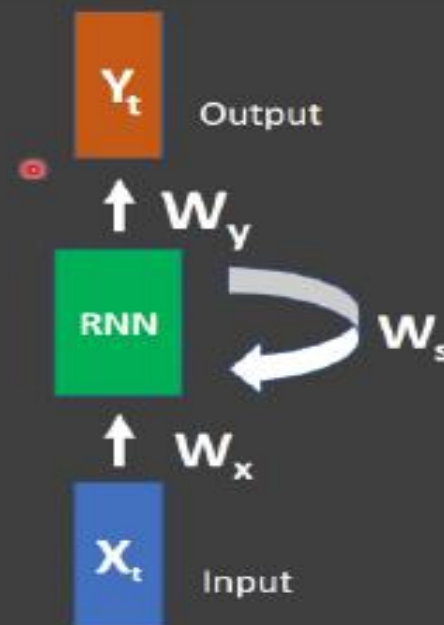
Feedforward network produce un valor que en muchos casos es una clase o una predicción. RNN es adecuado para datos de series temporales, donde una salida puede ser el siguiente valor en una secuencia, o los siguientes valores. La decisión depende de lo que requiera la aplicación, regresión de clasificación o previsión

Simple RNN


$$S_t = F_w(S_{t-1}, X_t)$$

$$S_t = \tanh(W_s S_{t-1} + W_x X_t)$$

$$Y_t = W_y S_t$$



RECURRENT NEURAL NETWORKS



The architecture of RNN.

<https://arxiv.org/abs/1409.3215>

Fuente: <https://www.tensorflow.org/guide/keras/rnn>


RECURRENT NEURAL NETWORKS



Capas RNN integradas: un ejemplo sencillo

Hay tres capas RNN integradas en Keras:

1. `keras.layers.SimpleRNN`, un RNN completamente conectado donde la salida del paso de tiempo anterior se alimenta al siguiente paso de tiempo.
2. `keras.layers.GRU`, propuesto por primera vez en [Cho et al., 2014](#).
3. `keras.layers.LSTM`, propuesto por primera vez en [Hochreiter & Schmidhuber, 1997](#).



The architecture of RNN.

RECURRENT NEURAL NETWORKS



Redes neuronales recurrentes (RNN) con Keras

Configuración

```
import numpy as np
import tensorflow as tf
from tensorflow import keras
from tensorflow.keras import layers
```




Fig. 1. Framework with input time series on the left, RNN model in the middle, and output time series on the right

Deep Learning – RNN - CNN

- TENSOR FLOW:
 - MLP (mlp.py)
 - RNN (rnn.py)
 - CNN (cnn.py)
- API Keras sobre Tensorflow

Tipos de Modelos en Tensor Flow para Procesamiento de Lenguaje Natural

Detección de texto tóxico

Codificador universal de oraciones

Segmentación semántica

Uso de lenguaje natural para responder preguntas

Tipos de Modelos en Tensor Flow en Imágenes

- Clasificación de imágenes
- Detección de objetos
- Segmentación del cuerpo
- Estimación de pose

TENSOR FLOW y ABSTRACCIÓN

- Facilita el proceso de adquisición de datos, modelos de capacitación, predicciones y refinamiento de resultados futuros.
- Creado por el equipo de Google Brain, es una biblioteca de código abierto para el cálculo numérico y el aprendizaje automático a gran escala.
- Reúne una gran cantidad de algoritmos y modelos de aprendizaje automático y de aprendizaje profundo.
- Utiliza Python para proporcionar una conveniente API de front-end para crear aplicaciones con el framework, mientras ejecuta esas aplicaciones en C++ de alto rendimiento

Tensorflow Codes (MLP, RNN, CNN) en MNIST dataset



mlp.py

```
Epoch 1 completed out of 10 loss: 1580448.2423095703
Epoch 2 completed out of 10 loss: 413067.3898963928
Epoch 3 completed out of 10 loss: 219827.5313282013
Epoch 4 completed out of 10 loss: 134923.41420912743
Epoch 5 completed out of 10 loss: 81669.84851998091
Epoch 6 completed out of 10 loss: 52424.493058502674
Epoch 7 completed out of 10 loss: 36300.166654587985
Epoch 8 completed out of 10 loss: 29144.069483664625
Epoch 9 completed out of 10 loss: 19910.462027701346
Epoch 10 completed out of 10 loss: 17675.114113055613
Accuracy: 0.9516
```

rnn.py

```
import tensorflow as tf
from tensorflow.examples.tutorials.mnist import input_data
from tensorflow.contrib import rnn
mnist = input_data.read_data_sets("/tmp/data/", one_hot=True)
```

```
hm_epochs = 5
n_classes = 10
batch_size = 256
chunk_size = 28
n_chunks = 28
rnn_size = 256
```

```
Epoch 1 completed out of 5 loss: 110.2273875772953
Epoch 2 completed out of 5 loss: 30.447120390832424
Epoch 3 completed out of 5 loss: 20.566452082246542
Epoch 4 completed out of 5 loss: 15.800598226487637
Epoch 5 completed out of 5 loss: 12.482633021660149
Accuracy: 0.9801
```

cnn.py

```
import tensorflow as tf
from tensorflow.examples.tutorials.mnist import input_data
mnist = input_data.read_data_sets("/tmp/data/", one_hot=True)
```

```
n_classes = 10
batch_size = 128
```

train_neural_network(x)

```
Epoch 0 completed out of 10 loss: 2921454.18756
Epoch 1 completed out of 10 loss: 574050.522736
Epoch 2 completed out of 10 loss: 305611.393166
Epoch 3 completed out of 10 loss: 197086.48822
Epoch 4 completed out of 10 loss: 137453.991611
Epoch 5 completed out of 10 loss: 101296.725072
Epoch 6 completed out of 10 loss: 78174.2471703
Epoch 7 completed out of 10 loss: 60469.5233727
Epoch 8 completed out of 10 loss: 50019.7263604
Epoch 9 completed out of 10 loss: 40857.0956538
Accuracy: 0.9681
```

Keras code (CNN) imágenes clasificador Cats and Dogs

```
from keras.layers import Conv2D, MaxPooling2D, ZeroPadding2D
from keras.layers import Dense, Activation, Dropout, Flatten
from keras import optimizers
from keras.models import Sequential
from keras.preprocessing.image import ImageDataGenerator
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.image as mpimg
from IPython.display import display
from PIL import Image
```

```
img_width = 150
img_height = 150
train_data_dir = 'data/train'
valid_data_dir = 'data/validation'
test_dir = 'test'
```

```
Epoch 45/50
 1/128 [.....] - ETA: 35s - loss: 8.4870e-07 - acc: 1.
 2/128 [.....] - ETA: 35s - loss: 0.0186 - acc: 1.0000
128/128 [=====] - 40s 315ms/step - loss: 0.2217 - acc:
0.9375 - val_loss: 1.4616 - val_acc: 0.7308
Epoch 46/50
128/128 [=====] - 40s 316ms/step - loss: 0.2559 - acc:
0.9414 - val_loss: 1.3608 - val_acc: 0.7380
Epoch 47/50
128/128 [=====] - 41s 319ms/step - loss: 0.1908 - acc:
0.9473 - val_loss: 1.3346 - val_acc: 0.7500
Epoch 48/50
128/128 [=====] - 40s 312ms/step - loss: 0.2821 - acc:
0.9160 - val_loss: 1.0499 - val_acc: 0.7380
Epoch 49/50
128/128 [=====] - 41s 320ms/step - loss: 0.1973 - acc:
0.9443 - val_loss: 1.7975 - val_acc: 0.7284
Epoch 50/50
 1/128 [.....] - ETA: 47s - loss: 6.1511e-05 - acc: 1.
 2/128 [.....] - ETA: 45s - loss: 6.2872e-04 - acc: 1.
 3/128 [.....] - ETA: 46s - loss: 0.0266 - acc: 1.0000
128/128 [=====] - 42s 326ms/step - loss: 0.2482 - acc:
0.9248 - val_loss: 1.2311 - val_acc: 0.7236
```




aws

Contacte con nosotros Support Español Mi cuenta Iniciar sesión

Productos Soluciones Precios Documentación Aprender Red de socios AWS Marketplace Habilitación para clientes Eventos Explorar más

Amazon Textract Información general Características Precios Recursos Preguntas frecuentes Clientes Socios

« Machine Learning


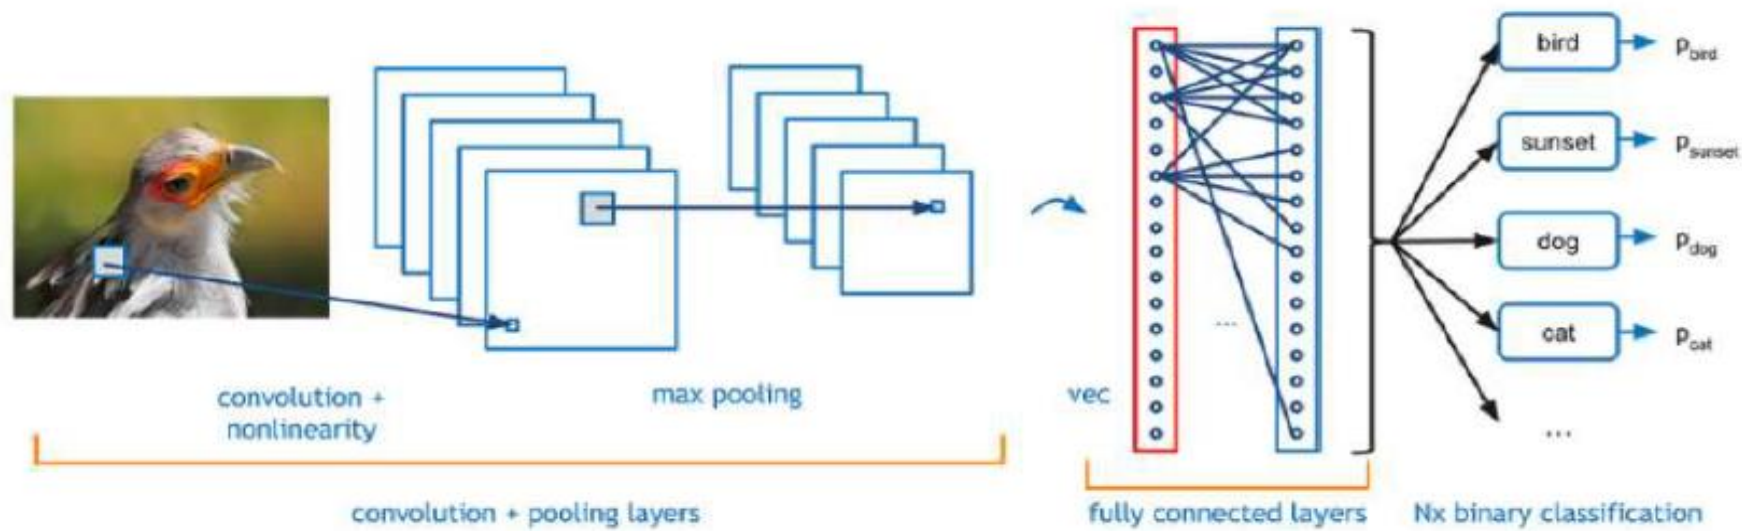
Amazon Textract

Extraiga automáticamente texto impreso, manuscrito y datos de cualquier documento

Introducción a Amazon Textract

Analice hasta 1000 p
mes de forma gratu
durante 3 meses
con el nivel gratuito de AWS

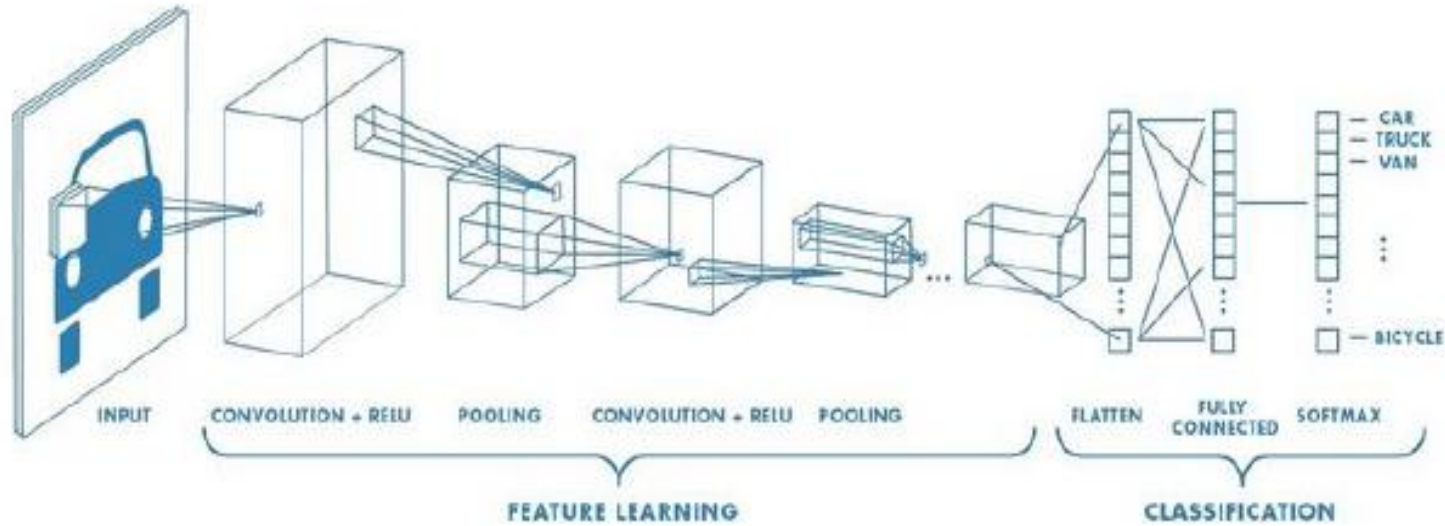
Extraiga texto y datos estructurados, como tablas y formularios, de documentos con	Vaya más allá del simple reconocimiento óptico de caracteres (OCR) mediante la extracción de relaciones,	Mejore la seguridad y la conformidad mediante privacidad de datos robusta, cifrado, controles	Implemente humanas con Amazon Aug AI (A2I) con f
--	--	---	--



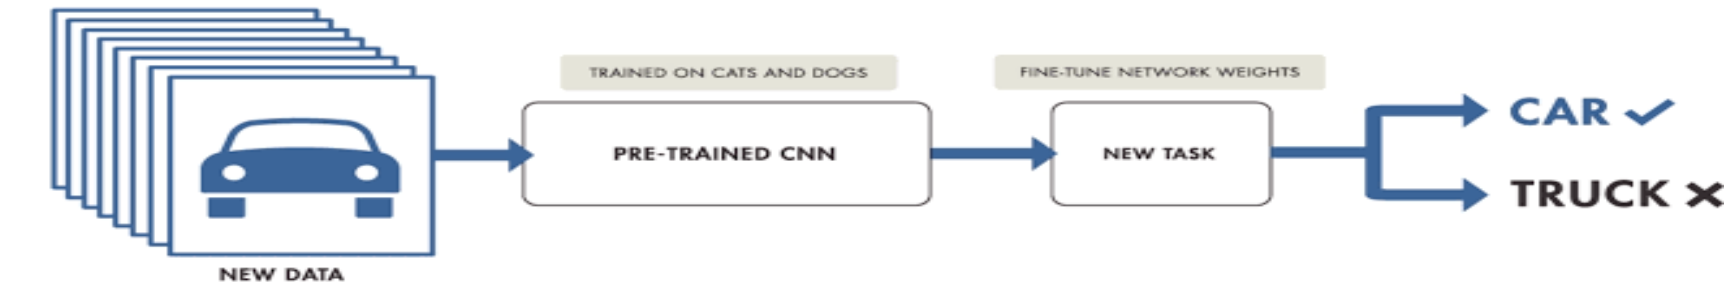
AUTOENCODER CONVOLUCIONAL

REPRESENTACIÓN LATENTE


TRANSFER LEARNING





TRANSFER LEARNING



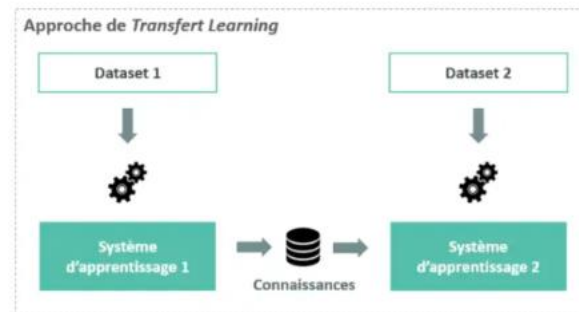

You Only Look Once (YOLO)



YOLO v2 network with DenseNet201 as a backend network for transfer learning



TRANSFER LEARNING – DEEP LEARNING



Tipos de TL

Inductive

Unsupervised

Transductive

Computer Vision

Natural Language Processing

<https://datascientest.com/es/que-es-el-transfer-learning>

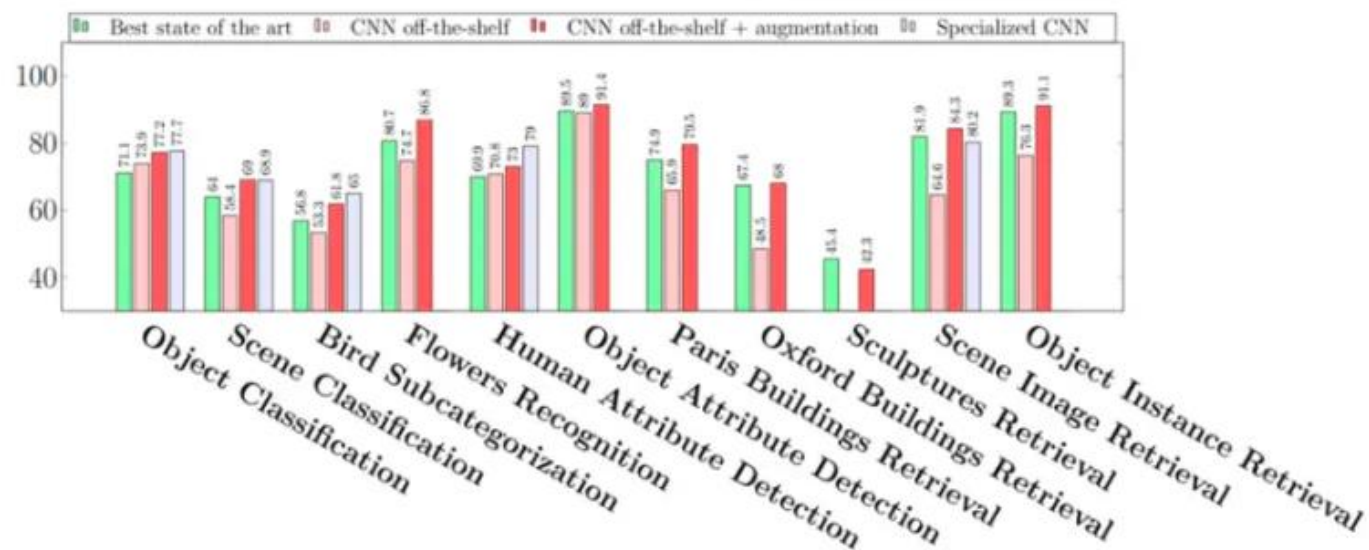
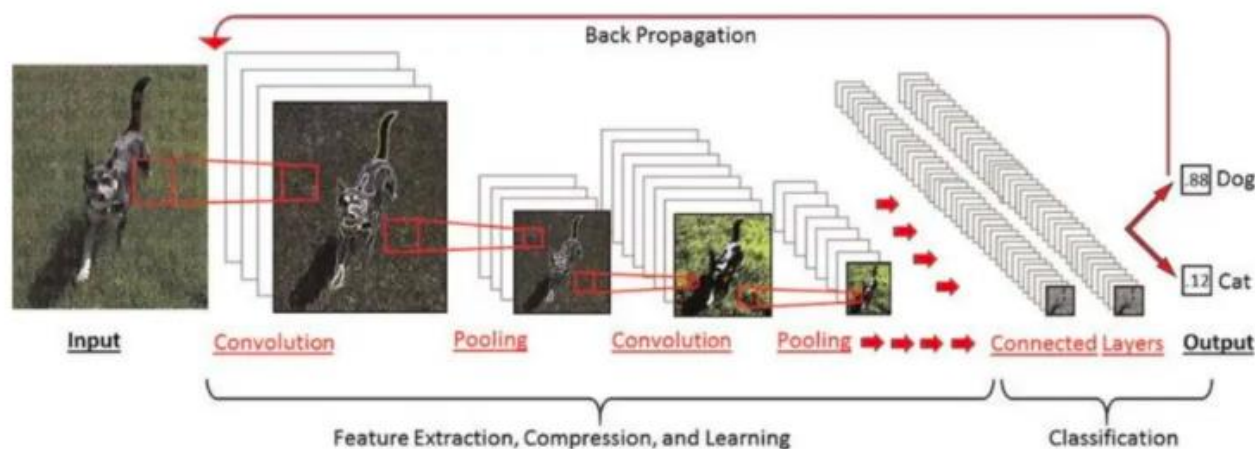


Figura 4: Desempeño de modelos Deep Learning específicamente entrenados sobre la tarea (verde) en comparación con modelos pre-entrenados (rojo, rosa).

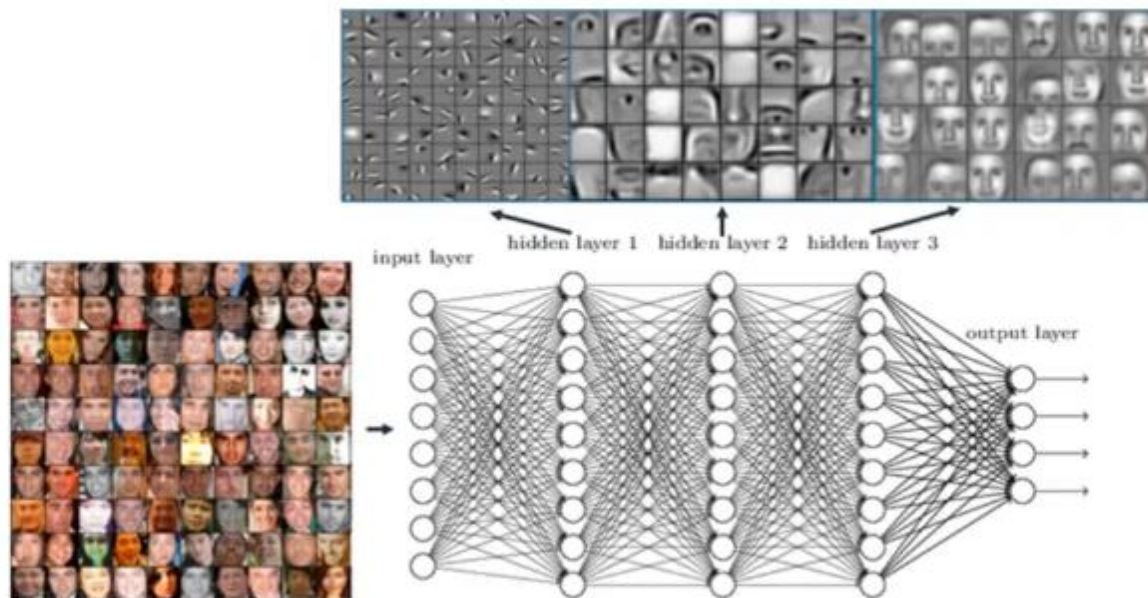


Figura 5 - Ejemplo de modelo de red de neuronas utilizado para reconocimiento facial.

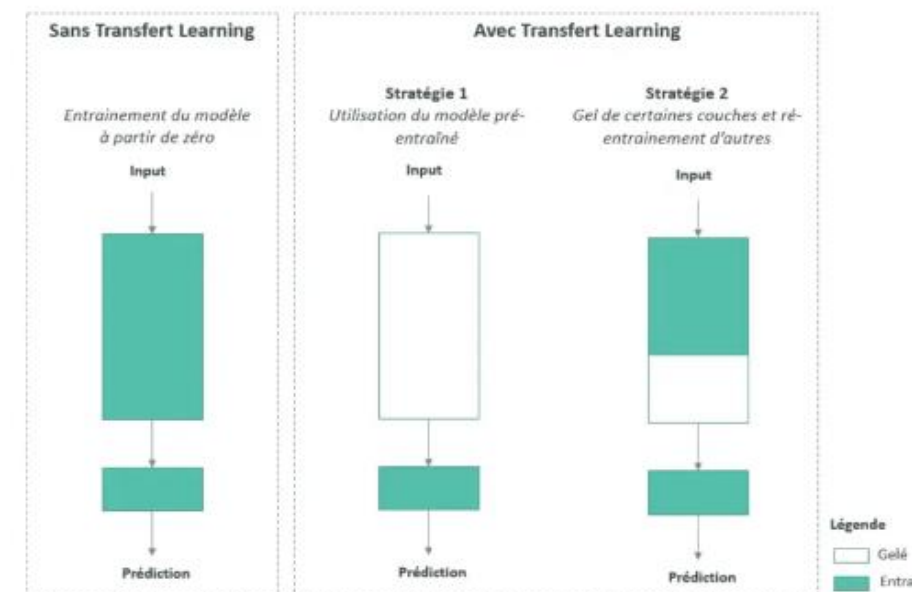


Figura 6: estrategia de Transfer Learning en Deep Learning

Entre los modelos más utilizados están:

- Computer Vision : [VGG-16](#), [VGG-19](#), [ResNet-50](#)
- NLP : [Word2Vec](#), [GloVe](#)

PyTorch

https://pytorch.org/hub/pytorch_vision_resnet/

Deep residual networks pre-trained on ImageNet

[View on Github](#)

[Open on Google Colab](#)

[Open Model Demo](#)

TensorFlow

https://www.tensorflow.org/api_docs/python/tf/keras/applications/resnet/ResNet101

https://www.tensorflow.org/api_docs/python/tf/keras/applications/resnet50/ResNet50

<https://www.kaggle.com/datasets/keras/vgg16>

Text Problem Domains

Embedding(176)

Language model(44)

Generation(3)

Preprocessing(7)

Retrieval question...(4)

Question answering(3)

Classification(2)

Segmentation(1)

To MEL(1)

See all

Image Problem Domains

Feature vector(194)

Classification(188)

Object detection(84)

Segmentation(32)

Generator(30)

Pose detection(14)

RNN agent(10)

Augmentation(8)

Classifier(5)

See all

Video Problem Domains

Classification(12)

Generation(5)

Audio text(3)

Text(2)

Audio Problem Domains

Embedding(4)

Speech synthesis(4)

Event classification(3)

STT(3)

Command detection(1)

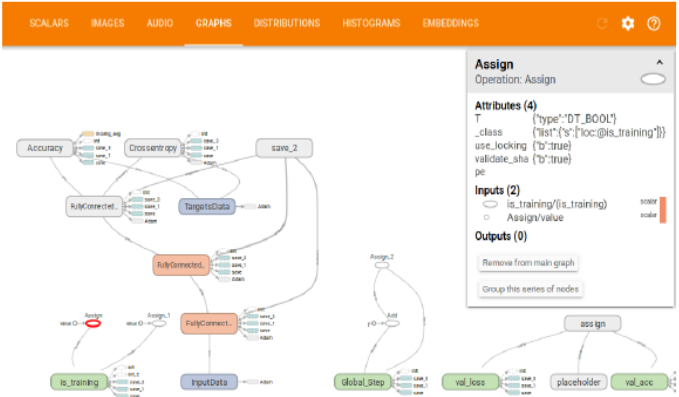
Pitch extraction(1)

Synthesis(1)

Modelos previamente entrenados en Tensor Flow

Modelos y conjuntos de datos

Explora repositorios y otros recursos para encontrar modelos, módulos y conjuntos de datos disponibles que creó la comunidad de TensorFlow.



Visualización: tensorboard

Data sets en Tensor Flow

- ▶ Audio
- ▶ Graphs
- ▶ Image
- ▶ Image classification
- ▶ Object detection
- ▶ Question answering
- ▶ Structured
- ▶ Summarization
- ▶ Text
- ▶ Translate
- ▶ Video
- ▶ Vision language

Recursos adicionales de conjuntos de datos


Explora otros conjuntos de datos disponibles para usar con TensorFlow.

Búsqueda de Datasets

Conjuntos de datos públicos de Google Cloud

Conjuntos de datos de Kaggle

2014 por Simonyan y Zisserman




Como Usuarios: recuperamos los pesos de las capas de convolución y simplemente entrenamos las 3 últimas capas

VGG16 Architecture

<https://datascientest.com/es/vgg->

Arquitectura del Algoritmo VGG16



ENTRENAMIENTO

Estructura Algoritmo VGG16

Pre-procesamiento: restar a cada píxel el valor RGB medio, calculado en el conjunto de entrenamiento

Input a 1ª capa de convolución: RGB de 224 x 224

El KERNEL, para todas las capas: 3x3

Max-Pooling, cada una: 2x2

Dos capas full connected de 4096 neuronas

Última capa: 1000 neuronas, softmax

RESNET

```
import torch
model = torch.hub.load('pytorch/vision:v0.10.0', 'resnet18', pretrained=True)
# or any of these variants
# model = torch.hub.load('pytorch/vision:v0.10.0', 'resnet34', pretrained=True)
# model = torch.hub.load('pytorch/vision:v0.10.0', 'resnet50', pretrained=True)
# model = torch.hub.load('pytorch/vision:v0.10.0', 'resnet101', pretrained=True)
# model = torch.hub.load('pytorch/vision:v0.10.0', 'resnet152', pretrained=True)
model.eval()
```

All pre-trained models expect input images normalized in the same way, i.e. mini-batches of 3-channel RGB images of shape $(3 \times H \times W)$, where H and W are expected to be at least 224. The images have to be loaded in to a range of $[0, 1]$ and then normalized using $\text{mean} = [0.485, 0.456, 0.406]$ and $\text{std} = [0.229, 0.224, 0.225]$.

Model Description


Resnet models were proposed in “Deep Residual Learning for Image Recognition”. Here we have the 5 versions of resnet models, which contains 18, 34, 50, 101, 152 layers respectively. Detailed model architectures can be found in Table 1. Their 1-crop error rates on imagenet dataset with pretrained models are listed below.

Model structure	Top-1 error	Top-5 error
resnet18	30.24	10.92
resnet34	26.70	8.58
resnet50	23.85	7.13
resnet101	22.63	6.44
resnet152	21.69	5.94

https://pytorch.org/hub/pytorch_vision_resnet/

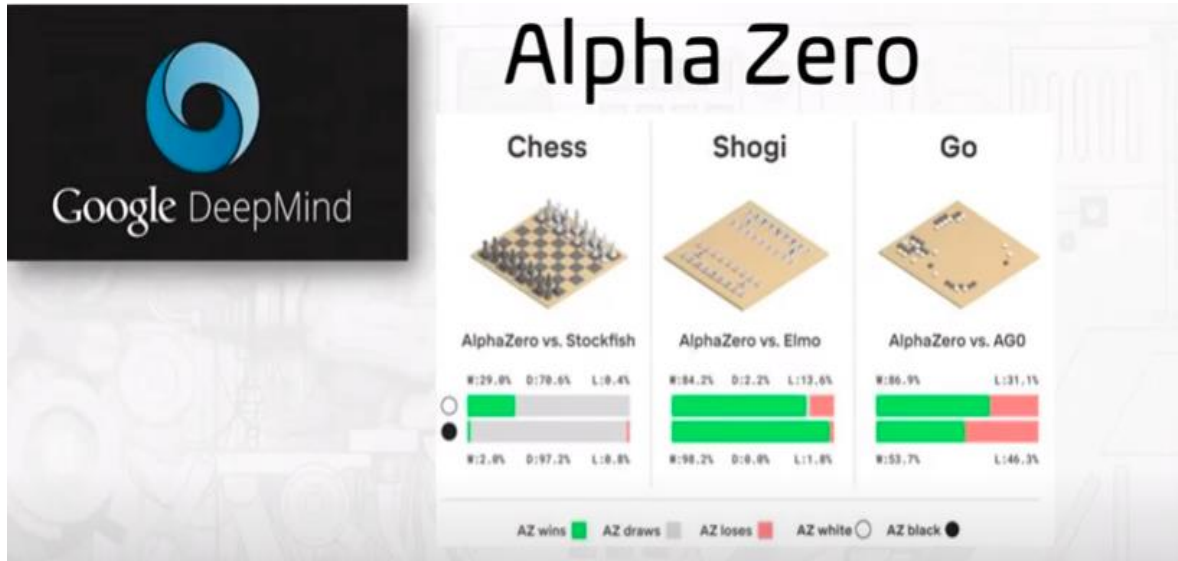
NEURAL NETWORKS

REINFORCEMENT LEARNING




NEURAL NETWORKS

REINFORCEMENT LEARNING



Silver, D., Hubert, T., Schrittwieser, J., Antonoglou, I., Lai, M., Guez, A., ... & Lillicrap, T. (2017). Mastering chess and shogi by self-play with a general reinforcement learning algorithm. *arXiv preprint arXiv:1712.01815*.

REINFORCEMENT LEARNING


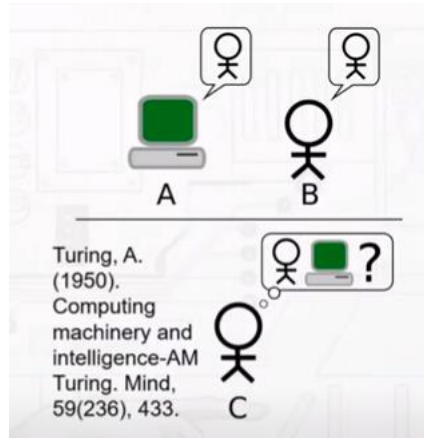


MODELOS DE IA GENERATIVA



Aprenden los patrones y la estructura de los datos de entrada para crear un contenido nuevo similar .

[Framework de alto nivel para trabajar con modelos diversos:](#)



ChatGPT & GPT-4 — How OpenAI Won the Natural Language Understanding War | by Col Jung | Apr, 2023

<https://generativeai.pub/the-road-to-chatgpt-gpt-4-how-deep-learning-revolutionised-natural-language-processing-835d89560577>

GENERATIVE ADVERSARIAL NETWORKS

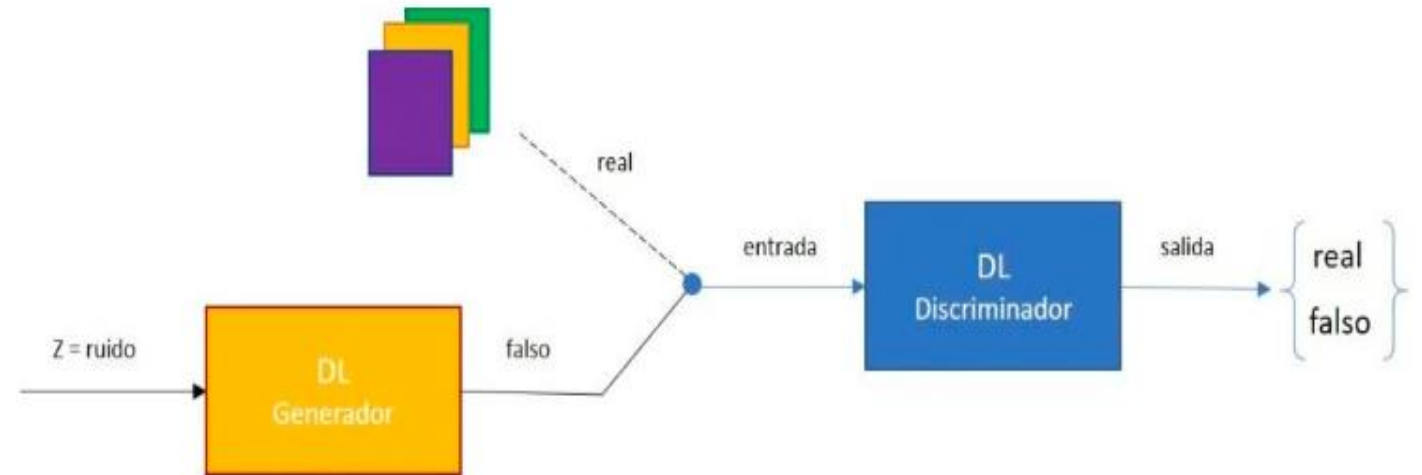

OPONEN DOS REDES CONVOLUCIONALES

COMO SI JUGARAN AL GATO Y AL RATÓN

**UNA DE ELLAS TIENE LA MISIÓN DE GENERAR “UN ROSTRO” LO MÁS
REALISTA POSIBLE**

**MIENTRAS, LA OTRA SE ESPECIALIZA EN DETECTAR “FOTOS” QUE NO SON
REALES**

**JUEGAN ENFRENTADAS, EVOLUCIONANDO AMBAS:
“TRATAMIENTO DE IMÁGENES”**




<https://www.iartificial.net/redes-neuronales-generativas-adversarias-gans/>

TRANSFORMERS

Aprendizaje profundo que prescinde de la Recurrencia y la Convolución

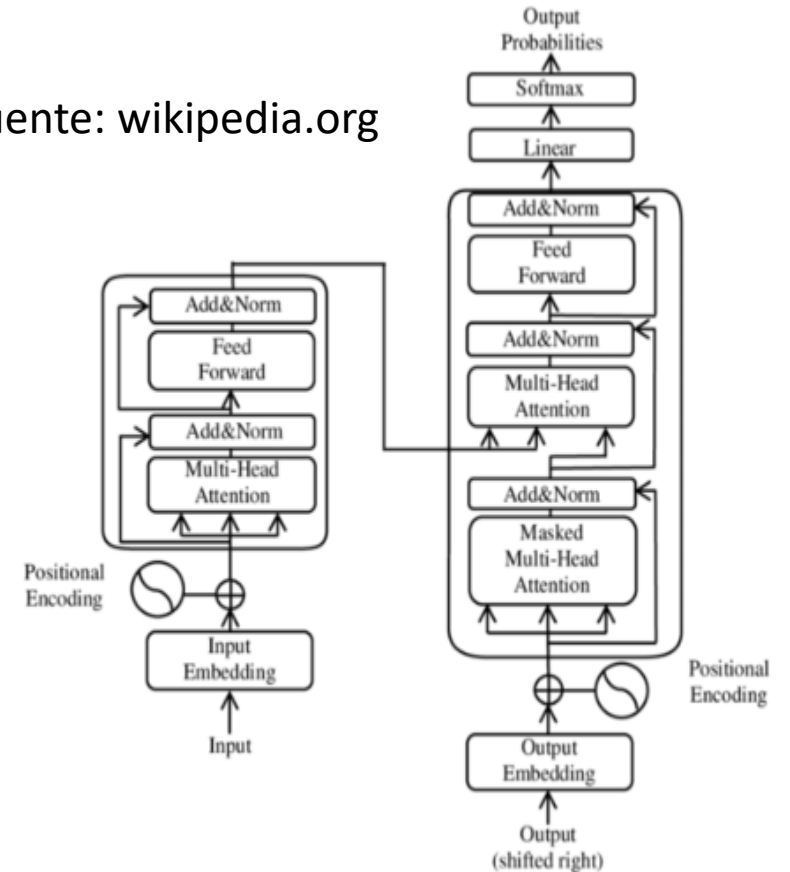
Basado en Mecanismos de atención

Codificación e Incrustación: Palabras a Tokens; Tokens a Vectores (word embedding) más ipositional encoding! (PE). Posición relativa de los tokens en la secuencia. Dimensión del original: 512!. La codificación posicional es una función sinusoidal



Fuente: /transformers-positional-encoding/

Fuente: wikipedia.org



Arquitectura del modelo transformador

$$PE_{(pos, 2i)} = \sin(pos/10000^{(2i/L)})$$


[Tutorial de Pytorch](#)

Attention Is All You Need

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Usz

The dominant sequence transduction models are based on the encoder-decoder architecture. We propose a new simple network architecture, the Transformer, being more parallelizable and requiring significantly less time. On the English-to-French translation task, our model establishes a new state-of-the-art. Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.

Comments: 15 pages, 5 figures
Subjects: **Computation and Language (cs.CL)**, Machine Learning (cs.LG)
Cite as: [arXiv:1706.03762](https://arxiv.org/abs/1706.03762) [cs.CL]



Kaiser, Illia Polosukhin

is in an encoder-decoder configuration. The best performing models also connect the encoder and decoder with recurrence and convolutions entirely. Experiments on two machine translation tasks show that the proposed model is competitive with the existing best results. On the WMT 2014 English-to-German translation task, improving over the existing best result of 1.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the existing models.



TRANSFORMER: RED NEURONAL NATIVA PARA PROCESAMIENTO DE LENGUAJE NATURAL APRENDE CONTEXTO BASADO EN DATOS QUE CONTIENEN SECUENCIAS

MECANISMOS DE ATENCIÓN

POR CASO, CHAT GPT (Generative Pre-training Transformer)

SU VENTAJA COMPARATIVA: UX

ESTÁ BASADO EN TEXTO

ES UN “GRAN MODELO DE LENGUAJE”

NO ES UN MODELO DE RAZONAMIENTO



SU DESEMPEÑO PARA RAZONAR:

DEDUCIR

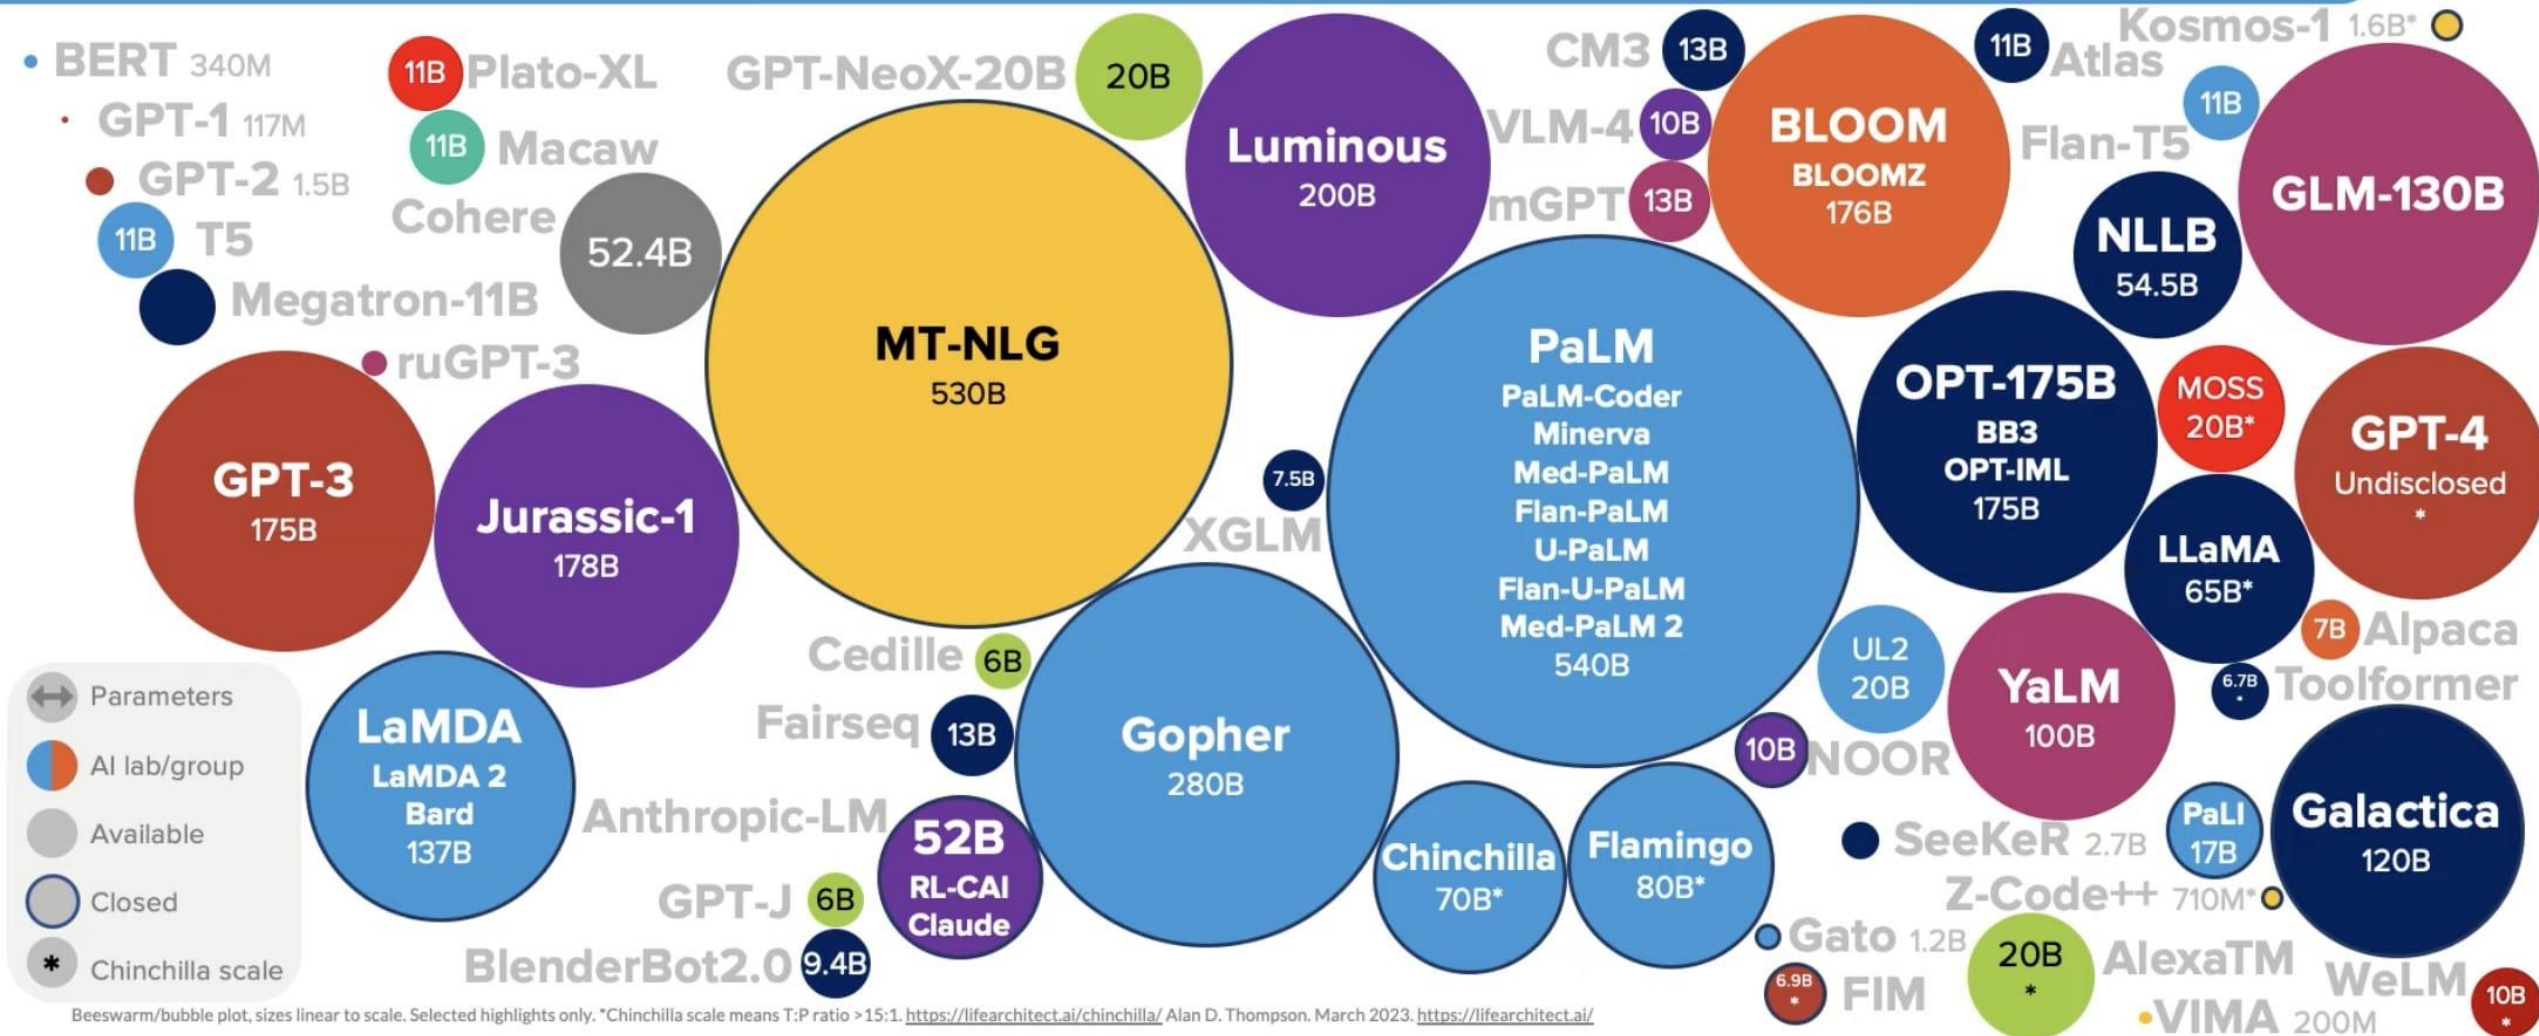
ABDUCIR


INDUCIR

TRANSFORMER (2017)



LANGUAGE MODEL SIZES TO MAR/2023





ChatGPT: Optimización de modelos de lenguaje para el diálogo

Hemos entrenado un modelo llamado ChatGPT que interactúa de forma conversacional. El formato de diálogo hace posible que ChatGPT responda preguntas de seguimiento, admita sus errores, cuestione premisas incorrectas y rechace solicitudes inapropiadas. ChatGPT es un modelo hermano de InstructGPT, que está capacitado para seguir una instrucción en un aviso y brindar una respuesta detallada.

PRUEBA CHATGPT ↗

ChatGPT

ChatGPT es un prototipo de **chatbot** de **inteligencia artificial** desarrollado en 2022 por **OpenAI** que se especializa en el diálogo. El chatbot es un gran **modelo de lenguaje** ajustado con técnicas de aprendizaje tanto **supervisadas** como de **refuerzo**. Se basa en el modelo GPT-3.5 de OpenAI, una versión mejorada de **GPT-3**.

ChatGPT se lanzó el 30 de noviembre de 2022¹ y ha llamado la atención por sus respuestas detalladas y articuladas, aunque se ha criticado su precisión fáctica. El servicio se lanzó inicialmente como gratuito para el público, con planes de monetizarlo más adelante. El 4 de diciembre, OpenAI calculaba que ChatGPT ya tenía más de un millón de usuarios.^{2 3}

<https://chat.openai.com/chat>

PROMPT ENGINEERING

<https://openai.com/research/instruction-following>

IN CONTEXT LEARNING (ICL)

FINE TUNING

RETROALIMENTACIÓN HUMANA: REINFORCEMENT LEARNING FROM HUMAN FEEDBACK (RLHF)

ALUCINACIONES: CONTENIDO FALSO

CONTENIDO NO DESEADO

CONTENIDO PELIGROSO

POLÍTICA DE VALORES Y PREFERENCIAS

¡GRACIAS!